

人工智能基础实验报告

基于PCA 的人脸识别技术

陈翊辉

PB15111656

PCA算法

PCA

在多元统计分析中，主成分分析（英语：Principal components analysis, PCA）是一种分析、简化数据集的技术。主成分分析经常用于减少数据集的维数，同时保持数据集中的对方差贡献最大的特征。这是通过保留低阶主成分，忽略高阶主成分做到的。这样低阶成分往往能够保留住数据的最重要方面。但是，这也不是一定的，要视具体应用而定。由于主成分分析依赖所给数据，所以数据的准确性对分析结果影响很大。

算法描述

PCA

这里使用矩阵的特征值分解计算PCA

将原始数据 X 从 n 维降到 k 维：

- 对数据做归一化处理 ($x_j := x_j - \mu_j$)
- 计算协方差矩阵($\Sigma = \frac{1}{m} X^T X$)
- 计算矩阵 Σ 的特征值与特征向量，按特征值的模降序排列([u, e, ~] = eig(sigma))
- 对数据降维 $z = u[:, k]^T * X$
-
- 若需要从降维的数据反推原数据 $X_a = u[:, k] * z$

该算法用Python及numpy实现比较容易，可以直接使用numpy的eig计算矩阵的特征值和特征向量。

人脸识别

使用曼哈顿距离作为识别的依据，在numpy中可以简单写作：

```
np.sum(np.abs(x-x_))
```

实验结果

不同阈值下降维后维数与正确率关系表（eig）

| 阈值 | 0.2 | 0.4 | 0.6 | 0.8 | 0.9 | 0.95 | 0.99 | 0.999 | 0.9999 | 1 |
|-----|--------|--------|--------|--------|--------|--------|--------|--------|--------|--------|
| 维数 | 2 | 4 | 10 | 42 | 99 | 163 | 266 | 311 | 318 | 10304 |
| 正确率 | 45.00% | 76.25% | 91.25% | 93.75% | 95.00% | 88.75% | 88.75% | 90.00% | 90.00% | 90.00% |

不同阈值下降维后维数与正确率关系表 (svd)

| 阈值 | 0.2 | 0.4 | 0.6 | 0.8 | 0.9 | 0.95 | 0.99 | 0.999 | 0.9999 | 1 |
|-----|--------|--------|--------|--------|--------|--------|--------|--------|--------|--------|
| 维数 | 2 | 4 | 10 | 41 | 98 | 162 | 266 | 311 | 318 | 10304 |
| 正确率 | 43.75% | 85.00% | 96.25% | 98.75% | 98.75% | 95.00% | 95.00% | 96.25% | 96.25% | 96.25% |

结果分析

从以上结果来看，基本达到PCA的目的，原始数据为10304维；

经过PCA处理，在threshold为0.99下，维数只有266维，而正确率能达到95.00%左右；

当threshold为0.4，维数仅有4维，这时正确率仍有85.00%。

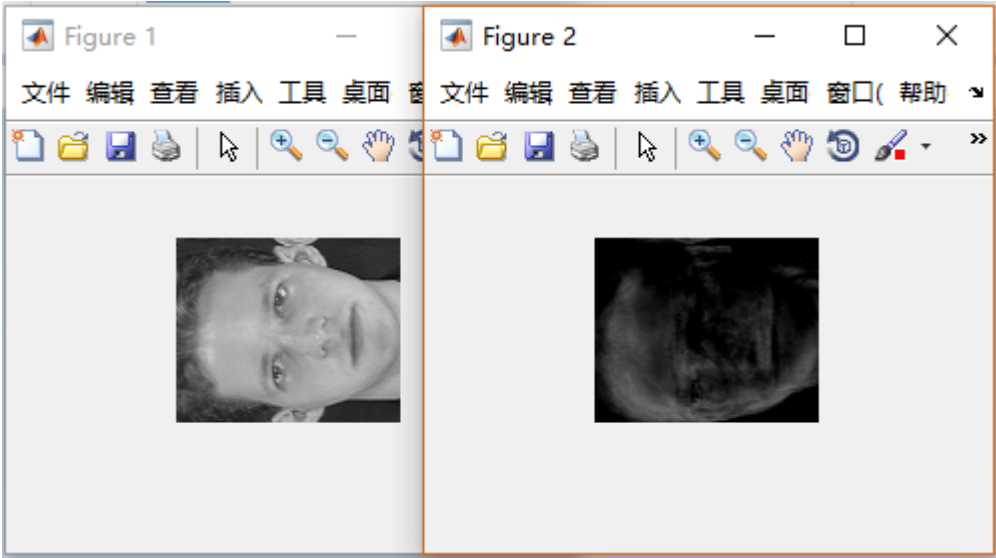
可以得到以下结论：

- 超过99.99%的“信息”集中在几百维
- 阈值越大，维数越大，
- 大体上维数越高识别正确率越高，但维数维40-100左右时正确率明显高于其他。

降维图像

可以用降维后的矩阵还原图像，得到类似“马赛克”的图像；

如99维后还原的图像（右）与原图（左）：



降维矩阵以thresold取0.99，163维为例，保存在文件 163d.mat 中(matlab格式)

对PCA的改进方案

图片预处理

整个PCA程序运行花费时间较多，通过对整个程序运行时间的分析发现，主要时间耗费在以下两项：

- 计算协方差矩阵($\Sigma = \frac{1}{m} X^T X$)
- 计算矩阵 Σ 的特征值与特征向量，按特征值的模降序排列($[u, e, \sim] = \text{eig}(\text{sigma})$)

原因在于矩阵 X 较大。

解决方案：

直接对图片作简单的压缩处理：将图片中相邻的4个像素取平均值压缩为1个像素。（卷积核为2*2全为1的矩阵，步长为2的卷积操作）。

经实验验证，该操作可以使PCA的运行时间从10min下降到50sec左右，而正确率基本不变。

使用奇异值代替特征值

通过查阅资料，使用奇异值分解作PCA优于特征值分解。

并且奇异值分解能避免计算特征值中出现复数。

而矩阵的奇异值分解使用numpy的svd函数可以直接算出，需要注意的是，numpy的svd与matlab的svd稍有区别。

实验结果显示，使用svd的PCA比eig的PCA在正确率上有明显优势，见实验结果。